Auditoria dos dados do Datathon

III Datathon IME-UFG · Grupo HP · gerado em 21/10/2026

Este documento lista os problemas encontrados nos dados entregues (pasta *dados/*) e **prova cada um** com números recalculados diretamente dos arquivos CSV e com registros reais de exemplo. Para cada problema mostramos: o que se esperava (pelo PDF de instruções ou por regra de negócio), o que os dados mostram, a regra exata usada para verificar (em `pandas`), o impacto nas trilhas e o tratamento que adotaremos.

Convenções: **vínculo** = linha de *dim_integrante* (ID_INTEGRANTE); **período** = 01/01/2025 a 30/09/2026; **vínculo do período** = admitido até 30/09/2026 e sem demissão ou demitido a partir de 01/01/2025. Severidade: CRÍTICO (impede um cálculo direto), ALTO (enviesa resultados se não tratado), MÉDIO (exige limpeza), BAIXO (cosmético).

Todos os números deste relatório são reproduzidos pelo script `relatorio_problemas.py`, entregue junto com o código.

Métodos de verificação e testes estatísticos

Os dados são um **censo** dos vínculos do Grupo HP, não uma amostra. Por isso, a maior parte das verificações é **determinística**: uma regra lógica (ex.: "data do ponto < data de admissão") aplicada a todos os registros e contada. Uma contagem maior que zero já prova o problema e não precisa de teste de hipótese. Usamos testes estatísticos quando a pergunta é sobre **padrão** (a falta de dados é aleatória? duas variáveis são redundantes? duas fontes concordam?). Com milhares de registros, quase todo p-valor sai muito pequeno; por isso reportamos sempre uma **medida de tamanho de efeito** junto com o p-valor.

Método	O que verifica	Critério de decisão	Problemas
Regras de integridade (contagem exata)	Datas fora do contrato, chaves órfãs, duplicados, valores fora do domínio, sobreposição de intervalos	Determinístico: contagem > 0 prova o problema	5, 6, 9–13, 17, 18
Qui-quadrado de independência (Pearson)	H0: duas variáveis categóricas são independentes. Aplicado a "ter ponto" x empresa/escala, para testar se a falta de dados é aleatória (MCAR)	p-valor + V de Cramér	1, 2, 4, 19
V de Cramér com correção de viés (Bergsma, 2013)	Força da associação entre duas categóricas, de 0 (independentes) a 1 (redundantes). Equivale a uma medida de colinearidade para variáveis categóricas	V >= 0,6 indica redundância forte	4, 19
Qui-quadrado de aderência	H0: o dia do mês do 1º registro de ponto é uniforme (dias 1 a 28). Rejeitar indica que o ponto segue um calendário fixo	p-valor + razão observado/esperado no dia 21	5
Kappa de Cohen	Concordância entre duas fontes que classificam o mesmo vínculo-dia como férias ou não (ponto x afastamentos), descontando o acaso	1 = concordância perfeita; < 0,8 indica divergência relevante	8
Correlação de Pearson e VIF	Colinearidade entre as colunas numéricas de minutos. $VIF_j = 1/(1-R^2_j)$, com R^2_j da regressão da coluna j nas demais	VIF > 10 indica multicolinearidade grave	20
Mediana / estatística descritiva	Escala praticada (dias com jornada por semana) e evolução do salário nominal	Comparação com o valor esperado pela regra de negócio	7, 14, 15

Nível de significância: 5%. Os testes foram feitos em Python (scipy.stats.chi2_contingency, scipy.stats.chisquare; kappa e VIF calculados diretamente).

Parte 1 — Cobertura dos dados

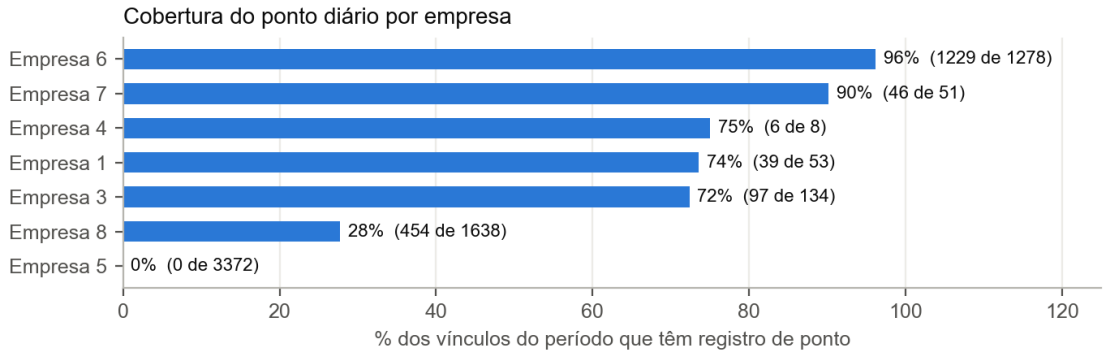
1. O ponto diário não cobre a maioria dos vínculos — e a empresa 5 não tem ponto nenhum [CRÍTICO] Afeta: T2, T3

O que se esperava: "Ponto diário: uma linha por vínculo por dia" de 01/01/2025 a 30/09/2026 (PDF de instruções).

O que os dados mostram: Só **1900** vínculos aparecem em *fBatidas*, contra **6.534** vínculos do período (29%). A empresa 5 — a maior, com 2.960 ativos hoje — tem **0** vínculos com ponto e apenas **1** afastamento registrado em 21 meses.

```
per = vínculos do período
per.groupby('CODCOLIGADA').ID_INTEGRANTE.apply(lambda s: s.isin(set(fBatidas.ID_INTEGRANTE)).mean())
```

empresa	vínculos do período	com ponto	eventos de afastamento	ativos hoje	% com ponto
1	53	39	362	0	74%
3	134	97	190	113	72%
4	8	6	2	6	75%
5	3.372	0	1	2.960	0%
6	1.278	1.229	3.088	781	96%
7	51	46	103	45	90%
8	1.638	454	1.306	1.016	28%



Teste estatístico: qui-quadrado de independência entre *ter ponto* e *empresa*: $\chi^2 = 4.487$, gl = 6, $p < 10^{-300}$, V de Cramér = 0,83. Mesmo excluindo a empresa 5: $\chi^2 = 1.430$, gl = 5, p = 3,9e-307. Rejeitamos H0: a falta de ponto **não é aleatória** (não é MCAR), logo médias calculadas só sobre quem tem ponto são viesadas.

Impacto: Não é possível medir faltas, atestados curtos e escala realizada para a empresa 5 nem para a maior parte da empresa 8. Qualquer taxa calculada só com o ponto descreve essencialmente a empresa 6.

Tratamento proposto: Calcular taxas de ausência onde há ponto e transferi-las para empresas sem ponto por função e tipo de jornada (estimativa por pares), sempre sinalizada como extrapolação e com intervalo de incerteza.

2. Na empresa 8, nenhum motorista em "REVEZAMENTO" tem ponto [CRÍTICO] Afeta: T2, T3

O que se esperava: A falta de ponto, se existisse, seria aleatória entre os integrantes.

O que os dados mostram: A ausência é **sistemática**: todos os 1029 vínculos da empresa 8 com escala REVEZAMENTO (praticamente todos motoristas de ônibus) estão fora de *fBatidas*. Quem tem ponto na empresa 8 é outro perfil de trabalhador.

```
e8 = per[per.CODCOLIGADA=='8']
pd.crosstab(e8.ESCALA, e8.ID_INTEGRANTE.isin(set(fBatidas.ID_INTEGRANTE)))
```

escala (cadastro)	sem ponto	com ponto
12X36	0	9
5X2	153	344
6X1	0	98

escala (cadastro)	sem ponto	com ponto
NAO IDENTIFICADA	2	3
REVEZAMENTO	1.029	0

Teste estatístico: qui-quadrado de independência entre *ter ponto* e *escala* na empresa 8: $\chi^2 = 1.103$, gl = 4, p = 1,4e-237, V de Cramér = 0,82. Associação quase perfeita: a ausência de ponto é determinada pela escala.

Impacto: O ponto da empresa 8 não representa seus motoristas de ônibus — usá-lo como se representasse produz viés de seleção.

Tratamento proposto: Para os motoristas da empresa 8, usar apenas *fAfastamentos* (que os cobre) e completar faltas com taxas de pares.

3. A escala da maior parte dos motoristas de ônibus é desconhecida [CRÍTICO] Afeta: T3

O que se esperava: "O horário de cada integrante define sua escala de trabalho, como 6x1, 5x2 ou 12x36" (PDF).

O que os dados mostram: 2.004 dos 4.921 ativos hoje (41%) têm escala JORNADA MENSAL, REVEZAMENTO ou NAO IDENTIFICADA — categorias que não dizem quantos dias por semana a pessoa trabalha. São justamente os motoristas de ônibus da empresa 5 (JORNADA MENSAL) e da empresa 8 (REVEZAMENTO), sem ponto para inferir a escala real.

```
ativos = dim_integrante[DATADEMISSAO.isna()] -> pd.crosstab(ativos.CODCOLIGADA, ativos.ESCALA)
```

empresa	12X36	5X2	6X1	JORNADA MENSAL	NAO IDENTIFICADA	REVEZAMENTO
3	0	113	0	0	0	0
4	4	1	0	0	1	0
5	0	1.730	1	1.229	0	0
6	11	118	619	0	33	0
7	0	8	30	0	7	0
8	9	203	70	0	1	733

Impacto: A Trilha 3 (40% da nota) pergunta quantas pessoas a mais seriam necessárias de 6x1 para 5x2; para estes grupos não se sabe sequer se hoje estão em 6x1.

Tratamento proposto: Tratar como cenários explícitos (ex.: "se REVEZAMENTO equivale a 6x1" / "se JORNADA MENSAL de 180h equivale a 5x2"), usando JORNADAMENSAL (minutos/mês) como pista, e reportar o resultado de cada cenário.

4. A escala 6x1 está concentrada numa única empresa e numa única função [ALTO]

Afeta: T3

O que se esperava: Para estimar o efeito da escala sobre a rotatividade, seria preciso comparar 6x1 e 5x2 em grupos semelhantes.

O que os dados mostram: Dos 1.201 vínculos 6x1 do período, **925 (77%)** são "MOTORISTA/CAMINHAO" da empresa 6. A associação (V de Cramér) entre escala e função é **0,62** e entre escala e empresa é **0,53**.

```
s6 = per[per.ESCALA=='6X1']; s6.groupby(['CODCOLIGADA','FUNCAO']).size()
```

empresa	função	vínculos 6x1
6	MOTORISTA/CAMINHAO	925
8	MANOBRISTA	27
1	TRABALHADOR DE PECUARIA	24
6	MOTORISTA DE ONIBUS	24
7	TRABALHADOR DE PECUARIA	21
6	OUTRAS FUNCOES	19

Teste estatístico: qui-quadrado escala x função: $\chi^2 = 13.151$, gl = 525, $p < 10^{-300}$, V = 0,62; escala x empresa: $\chi^2 = 9.328$, gl = 30, $p < 10^{-300}$, V = 0,53. Associação forte (V > 0,5): escala, função e empresa são colineares, e o efeito isolado da escala não é identificável sem controles.

Impacto: Uma comparação ingênua "turnover 6x1 vs 5x2" mede, na prática, "motoristas de caminhão da empresa 6 vs. o resto".

Tratamento proposto: Comparar dentro da mesma empresa e função (estratificação/regressão com controles) e explorar quem mudou de horário ao longo do ponto; declarar a limitação.

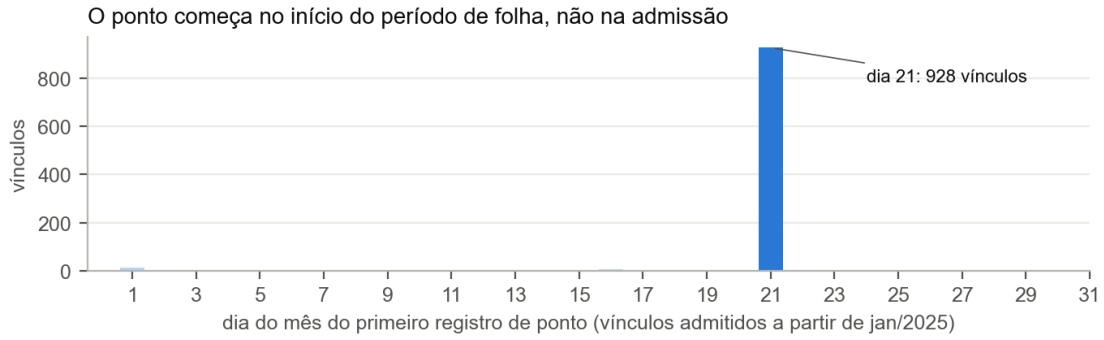
Parte 2 — Registros que contradizem o cadastro

5. O ponto tem registros antes da admissão e depois da demissão [ALTO] Afeta: T1, T2, T3

O que se esperava: Um vínculo só pode ter ponto entre a data de admissão e a de demissão.

O que os dados mostram: 13.064 linhas são anteriores à admissão e **7.748** posteriores à demissão, em **1.246** vínculos. O padrão revela a causa: entre os vínculos admitidos no período, **98%** têm o primeiro registro de ponto no **dia 21** do mês — o ponto é gerado por **período de apuração da folha (21 a 20)**, não pelo contrato.

```
bx = fBatidas JOIN dim_integrante
(bx.DATA < bx.DATAADMISSAO).sum(); (bx.DATA > bx.DATADEMISSAO).sum()
primeiro_registro.dt.day.value_counts() # pico no dia 21
```



Teste estatístico: qui-quadrado de aderência à distribuição uniforme nos dias 1 a 28 (H0: o 1º registro pode cair em qualquer dia, como as admissões): $\chi^2 = 24.521$, $gl = 27$, $p < 10^{-300}$. No dia 21 há 928 vínculos contra 33,8 esperados (27x). Para comparação, o dia da **admissão** desses vínculos se distribui de forma bem mais espalhada (máximo de 80 num único dia).

Exemplo real — vínculo **8-63897**, admitido em 15/08/2025 e demitido em 26/01/2026

vínculo	data	sit.	prev.	trab.	falta	abono	extra
8-63897	2025-07-21		0	0	0	0	0
8-63897	2025-07-22		0	0	0	0	0
8-63897	2025-07-23		0	0	0	0	0
8-63897	2025-08-15	A	528	529	0	1	0
8-63897	2025-08-16	A	0	0	0	0	0
8-63897	2026-02-19	D	0	0	0	0	0
8-63897	2026-02-20	D	0	0	0	0	0

Impacto: Dias fora do contrato entram como se fossem dias do vínculo: inflam headcount diário e podem aparecer como falta/folga.

Tratamento proposto: Filtrar o ponto por `DATAADMISSAO <= DATA <= DATADEMISSAO` antes de qualquer cálculo.

6. Há meses inteiros sem ponto dentro do contrato [MÉDIO] Afeta: T2

O que se esperava: Entre admissão e demissão (limitadas ao período), uma linha por dia.

O que os dados mostram: 533 dos 1.870 vínculos com ponto têm dias faltando dentro do contrato, somando **23.183** dias. A mediana entre eles é de **31 dias** — tipicamente um mês inteiro ausente.

```
esperado = dias entre max(adm, 01/01/25) e min(dem, 30/09/26); faltando = esperado - linhas de ponto dentro do contrato
```

Exemplo real — vínculo **8-24572**: dias de ponto registrados por mês

2025-01	2025-02	2025-03	2025-04	2025-05	2025-06	2025-07	2025-08	2025-09	2025-10	2025-11	2025-12
20	8	31	30	31	30	31	31	30	31	30	31

2026-01	2026-02	2026-03	2026-04	2026-05	2026-06	2026-07	2026-08	2026-09
31	28	31	30	31	30	31	31	30

Impacto: Ausências nesses meses ficam invisíveis; taxas por dia calculadas com o denominador errado.

Tratamento proposto: Usar como denominador apenas os dias efetivamente registrados e marcar os meses sem ponto como faltantes (não como presença).

7. A escala do cadastro nem sempre é a escala praticada [ALTO] Afeta: T3

O que se esperava: Um horário 6x1 deveria ter ~6 dias com jornada prevista por semana; um 5x2, ~5.

O que os dados mostram: Contando os dias com MINUTOS_PREVISTOS > 0 por semana no ponto (mediana por vínculo e horário), **205** combinações vínculo-horário rotuladas 5X2 não trabalham 5 dias e **169** rotuladas 6X1 não trabalham 6. Além disso, **22%** das linhas de ponto usam um horário diferente do que está no cadastro: o cadastro guarda só o horário atual.

```
dias/semana = nº de dias com MINUTOS_PREVISTOS>0 por (vínculo, horário, semana) -> mediana
(fBatidas.ID_HORARIO != dim_integrante.ID_HORARIO).mean()
```

escala no cadastro	1 dia(s)/sem	2 dia(s)/sem	3 dia(s)/sem	4 dia(s)/sem	5 dia(s)/sem	6 dia(s)/sem
12X36	1	1	35	2	0	0
5X2	13	8	4	126	838	54
6X1	9	4	3	71	82	1.508
NAO IDENTIFICADA	1	1	0	3	34	36

Impacto: Classificar quem está em 6x1 pelo cadastro erra uma parcela relevante; e o histórico de mudança de escala se perde.

Tratamento proposto: Definir a escala de cada vínculo-mês pelo ponto (dias trabalhados observados) e usar o cadastro só como fallback.

8. Férias: o ponto e a tabela de afastamentos discordam [MÉDIO] Afeta: T2

O que se esperava: Os dias com situação "F" (férias) no ponto deveriam coincidir com os eventos FERIAS de *fAfastamentos*.

O que os dados mostram: Para vínculos que têm ponto: **37.915** dias de férias no ponto e **33.578** em afastamentos. Coincidem **30.325**; **7.590** estão só no ponto e **3.253** só em afastamentos. Além disso, as empresas 4 e 5 não têm nenhum evento de férias em 21 meses. E **75** vínculos têm sequências de mais de 30 dias seguidos com situação "F" no ponto (máximo de **472 dias**), quando as férias (CLT) são de no máximo 30 dias por período aquisitivo — provavelmente afastamentos longos registrados como férias.

```
dias_ponto = {(vínculo, data) : SITUACAO_NA_DATA=='F'}
dias_afast = {(vínculo, d) : d em [DT_INICIO, DT_FIM] e CATEGORIA_EVENTO=='FERIAS'}
```

Exemplo real — vínculo **6-68095**: eventos FERIAS registrados e meses com situação F no ponto

Teste estatístico: kappa de Cohen entre as duas fontes, sobre os 580.512 vínculo-dias com ponto dentro do contrato: concordância bruta = 98,3% (inflada porque a maioria dos dias não é férias), κ = **0,85**. A concordância é boa (κ > 0,8), mas não perfeita: 10.843 vínculo-dias de férias são registrados por apenas uma das fontes, o que equivale a cerca de 26% de todos os dias de férias.

ID_INTEGRANTE	CATEGORIA_EVENTO	DT_INICIO	DT_FIM
6-68095	FERIAS	2026-03-19	2026-04-17

mês	primeiro	ultimo	dias
2025-01	2025-01-01	2025-01-31	31
2025-02	2025-02-01	2025-02-28	28
2025-03	2025-03-01	2025-03-31	31
2025-04	2025-04-01	2025-04-30	30
2025-05	2025-05-01	2025-05-31	31

mês	primeiro	ultimo	dias
2025-06	2025-06-01	2025-06-30	30
2025-07	2025-07-01	2025-07-31	31
2025-08	2025-08-01	2025-08-31	31
2025-09	2025-09-01	2025-09-30	30
2025-10	2025-10-01	2025-10-31	31
2025-11	2025-11-01	2025-11-30	30
2025-12	2025-12-01	2025-12-31	31
2026-01	2026-01-01	2026-01-31	31
2026-02	2026-02-01	2026-02-28	28
2026-03	2026-03-01	2026-03-31	31
2026-04	2026-04-01	2026-04-17	17

Impacto: Usar só uma das fontes subestima as férias e, portanto, o quadro de feristas.

Tratamento proposto: Usar a união das duas fontes (dia de férias se aparece em qualquer uma) e reportar a divergência.

9. O evento DESLIGAMENTO em afastamentos não confere com o cadastro [MÉDIO]

Afeta: T1

O que se esperava: Cada demissão do período apareceria como evento DESLIGAMENTO, na mesma data.

O que os dados mostram: O cadastro tem **1.578** demissões no período; só **744** têm evento DESLIGAMENTO (nenhuma da empresa 5). Dos 1.098 eventos, **260** têm data diferente da demissão do cadastro — com diferença mediana de **-615 dias** e máxima de 6.555 dias.

```
dl = fAfastamentos[CATEGORIA_EVENTO=='DESLIGAMENTO'] JOIN dim_integrante; (dl.DT_INICIO - dl.DATADEMISSAO).dt.days
```

vínculo	DESLIGAMENTO (afast.)	DATADEMISSAO (cadastro)	diferença (dias)
1-57968	2001-04-01	2019-03-13	-6.555
1-46906	2011-01-01	2012-08-31	-608

Impacto: Se a rotatividade fosse contada por *fAfastamentos*, metade das saídas desapareceria.

Tratamento proposto: Usar exclusivamente *dim_integrante* (DATADEMISSAO + CATEGORIA_DESLIGAMENTO) para a Trilha 1.

10. fAfastamentos: duplicados, sobreposições e eventos fora do período [MÉDIO]

Afeta: T2

O que se esperava: "Afastamentos ativos entre 01/01/2025 e 30/09/2026" (PDF), um registro por evento.

O que os dados mostram: 31 duplicados exatos; **32** eventos que começam antes do fim do evento anterior do mesmo vínculo; **333** eventos inteiramente fora do período; **36** sem data de fim (INSS: 15, APOSENTADORIA POR INCAPACIDADE: 12, LICENCA SEM VENCIMENTO: 5, ACIDENTE DE TRABALHO: 3, OUTROS: 1).

```
fAfastamentos.duplicated(['ID_INTEGRANTE','CATEGORIA_EVENTO','DT_INICIO','DT_FIM'])
```

vínculo	CATEGORIA_EVENTO	DT_INICIO	DT_FIM
3-86481	DOENCA ATE 15 DIAS (EMPRESA)	2025-01-02	2025-01-02
3-86481	DOENCA ATE 15 DIAS (EMPRESA)	2025-01-02	2025-01-02
6-10975	DESLIGAMENTO	2025-01-10	2025-01-10
6-10975	DESLIGAMENTO	2025-01-10	2025-01-10

Impacto: Duplicados e sobreposições contam a mesma ausência duas vezes.

Tratamento proposto: Deduplicar, unir intervalos sobrepostos por vínculo e recortar no período; eventos sem fim tratados como em curso até 30/09/2026.

11. Minutos impossíveis e ausências "invisíveis" no ponto [MÉDIO] Afeta: T2

O que se esperava: Minutos trabalhados entre 0 e 1.440 (24h) por dia; um dia previsto sem trabalho deveria virar falta ou abono.

O que os dados mostram: 67 dias com minutos trabalhados negativos (mínimo -992); **156** com mais de 24h (máximo 10.561 min = 7,3 dias); **221** com mais de 12h extras. E **13.680** dias com situação Ativo, jornada prevista, zero trabalhado, zero falta e zero abono — ausências que não aparecem como falta.

```
(MINUTOS_TRABALHADOS < 0) | (MINUTOS_TRABALHADOS > 1440) | (MINUTOS_EXTRA > 720)
SITUACAO=='A' & PREVISTOS>0 & TRABALHADOS==0 & FALTA==0 & ABONO==0
```

vínculo	data	sit.	prev.	trab.	falta	abono	extra
7-52143	2026-04-15	A	0	-992	0	0	0
7-10500	2026-04-18	A	0	-693	0	0	0
8-72158	2025-01-06	A	528	10.561	0	0	10.033
8-64468	2025-01-05	A	0	10.081	0	0	10.081
6-86071	2025-03-06	A	400	0	0	0	0
6-86071	2025-06-10	A	418	0	0	0	0

Impacto: Somas de horas e taxas de falta distorcidas; parte das ausências reais fica subnotificada.

Tratamento proposto: Truncar minutos ao intervalo [0, 1440]; tratar o dia previsto e não trabalhado sem justificativa como ausência não registrada (análise de sensibilidade com e sem).

12. Ponto de vínculos que não existem no cadastro [BAIXO] Afeta: T2

O que se esperava: Todo ID_INTEGRANTE de *fBatidas* existe em *dim_integrante*.

O que os dados mostram: 150 linhas de ponto de **15** vínculos sem cadastro: 6-94846, 8-18603, 6-18035, 6-32648, 6-10818, 6-88667, 8-59873, 6-83622…

```
~fBatidas.ID_INTEGRANTE.isin(dim_integrante.ID_INTEGRANTE)
```

Impacto: Sem empresa/função/datas, essas linhas não podem ser usadas.

Tratamento proposto: Descartar (impacto desprezível).

13. A mesma pessoa com vínculos sobrepostos ou recontratada em dias [MÉDIO]

Afeta: T1

O que se esperava: Uma admissão nova representa entrada de pessoa e uma demissão, saída — base da fórmula de turnover.

O que os dados mostram: 221 casos em que a pessoa (CODPESSOA) é admitida de novo **antes** da demissão do vínculo anterior (65 na mesma empresa) e **157** recontratações em até 3 dias (26 para outra empresa do grupo). Há 915 admissões com motivo "Transferência".

```
ordenar por CODPESSOA, DATAADMISSAO; gap = próxima_admissão - DATADEMISSAO; gap < 0 (sobreposto), 0<=gap<=3 (recontratação)
```

pessoa	vínculo 1	admissão 1	demissão 1	vínculo 2	admissão 2
00132	6-53198	2025-04-03	2025-09-30	8-28646	2025-04-03
00149	8-99331	2007-11-20	2011-06-07	8-93417	2007-11-20
00204	8-88900	2023-11-13	2026-01-01	3-74249	2023-11-13

Impacto: Transferências e trocas de matrícula entram como admissão + rescisão, inflando o turnover sem que ninguém tenha saído do grupo.

Tratamento proposto: Calcular o turnover em duas versões: oficial (por vínculo) e por pessoa, desconsiderando transferências e recontratações em até 3 dias.

Parte 3 — Variáveis que não significam o que parecem

14. Salário é nominal e da época da última alteração [MÉDIO] Afeta: Custo

O que se esperava: "Salário de referência" comparável entre integrantes.

O que os dados mostram: A mediana salarial por ano de demissão cresce de 2000: R$ 302, 2004: R$ 572, 2008: R$ 1.477, 2012: R$ 1.477, 2016: R$ 1.837, 2020: R$ 1.477, 2024: R$ 1.698; ativos hoje: R$ 1.837. O valor é o da época, sem correção.

```
dim_integrante[DATADEMISSAO.notna()].groupby(ano(DATADEMISSAO)).SALARIO.median()
```

Impacto: Comparar salários entre períodos ou usá-los como preditor mistura inflação com perfil.

Tratamento proposto: Usar salário só dos ativos (custo do contrato) ou relativizar ao piso da função no mesmo ano.

15. FAIXA_ETARIA não é a idade atual (nem documentada) [BAIXO] Afeta: T1

O que se esperava: Faixa etária do integrante.

O que os dados mostram: Vínculos admitidos antes de 1990 — que hoje teriam ao menos 50 anos — aparecem com faixas 53 a 57, 38 a 42, 58 a 62, 43 a 47, 48 a 52. A faixa parece ser a idade na demissão (ou na última atualização), e não há documentação. 18 vínculos sem faixa.

```
dim_integrante[ano(DATAADMISSAO) < 1990].FAIXA_ETARIA.value_counts()
```

Impacto: Usar faixa etária como preditor exige saber a data de referência.

Tratamento proposto: Usar apenas para vínculos do período (onde a idade na saída é próxima da atual) e declarar a premissa.

16. Colunas prometidas ausentes ou sem informação [MÉDIO] Afeta: T1, T3

O que se esperava: PDF cita "cargo padronizado (que agrupa funções equivalentes)"; dim_horario traz turno e tipo de jornada.

O que os dados mostram: *dim_funcao* só tem as colunas ID_FUNCAO, CODCOLIGADA, CODFUNCAO, FUNCAO — **não existe cargo padronizado**. Em *dim_horario*, TURNO é "NAO IDENTIFICADO" em **100%** dos horários e TIPO_JORNADA é "SEM INTERVALO DEFINIDO" em **89%**. 9.612 dos 10.175 códigos de função se chamam "OUTRAS FUNCOES" (495 vínculos do período). Há grafias duplicadas, como "COBRADOR" e "COBRADOR(A)". Faltam CODCCUSTO em 349 e CODEQUIPE em 361 vínculos.

```
dim_horario.TURNO.value_counts(normalize=True); dim_funcao.FUNCAO.value_counts()
```

Impacto: Agrupar funções equivalentes e segmentar por turno não é possível com os dados entregues.

Tratamento proposto: Criar um agrupamento próprio de funções (motorista de ônibus, cobrador, motorista de caminhão, aprendiz, outros) e ignorar TURNO/TIPO_JORNADA.

17. Feriados do ponto não batem com dim_feriados [BAIXO] Afeta: T2, T3

O que se esperava: FERIADO = 1 no ponto exatamente nas datas de *dim_feriados*.

O que os dados mostram: **1.138** linhas marcadas como feriado em datas que não estão na tabela: 2025-07-26, 2026-03-19, 2026-05-11, 2026-07-26 (provavelmente feriados municipais). E datas da tabela dentro do período nunca marcadas no ponto: 2025-03-03, 2025-03-04, 2025-03-05, 2026-02-16, 2026-02-17, 2026-02-18 (carnaval/quarta de cinzas — pontos facultativos).

```
fBatidas[(FERIADO=='1') & ~DATA.isin(dim_feriados.data)].DATA.unique()
```

Impacto: Pequeno efeito na contagem de dias úteis a cobrir.

Tratamento proposto: Usar o FERIADO do próprio ponto (reflete o calendário local) e dim_feriados só para projeção.

18. Datas incoerentes no cadastro [BAIXO] Afeta: T1

O que se esperava: DATADEMISSAO posterior à DATAADMISSAO.

O que os dados mostram: **1** vínculo com demissão anterior à admissão (8-86991: 2004-09-03 → 2004-09-01) e **35** contratos encerrados no mesmo dia da admissão.

```
(DATADEMISSAO < DATAADMISSAO).sum(); (DATADEMISSAO == DATAADMISSAO).sum()
```

Impacto: Desprezível em volume.

Tratamento proposto: Excluir o caso negativo; manter os de 0 dias (são admissões e rescisões reais para o turnover).

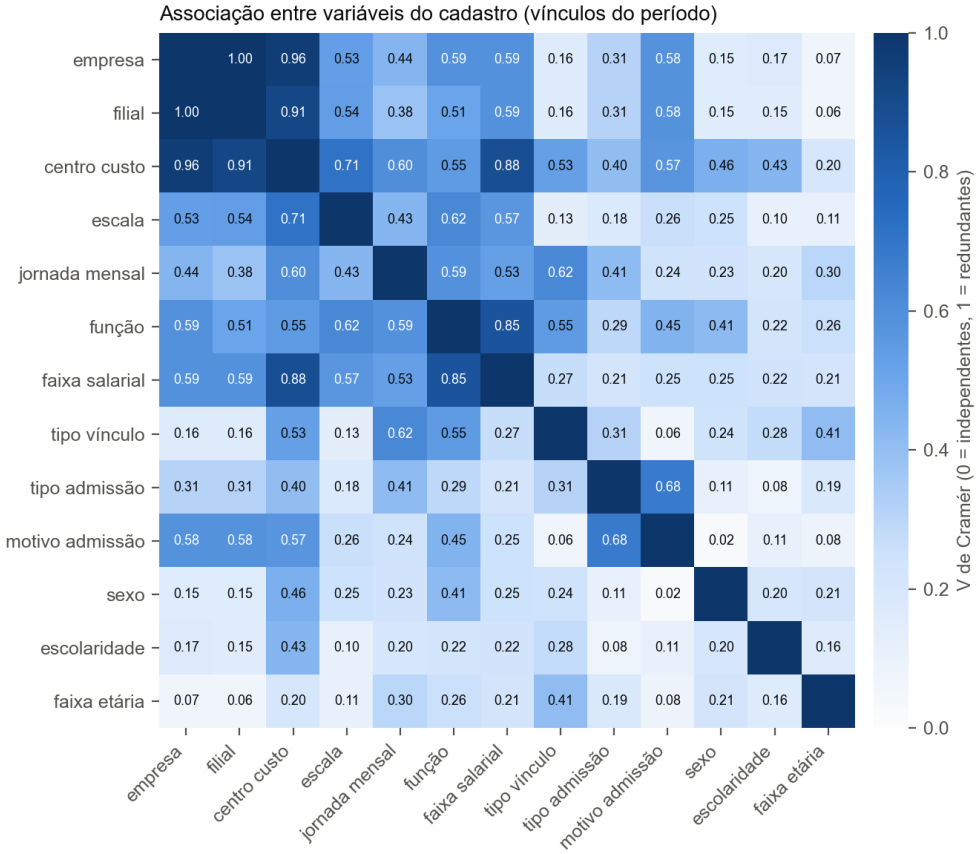
Parte 4 — Colinearidade e redundância entre variáveis

19. Variáveis categóricas do cadastro são fortemente redundantes [MÉDIO] Afeta: T1, T3

O que se esperava: Variáveis explicativas razoavelmente independentes para um modelo de rotatividade.

O que os dados mostram: Medimos a associação par a par com o V de Cramér (corrigido para viés, Bergsma 2013) nos vínculos do período. Pares com V ≥ 0,60: **empresa ~ filial** (1,00); **empresa ~ centro custo** (0,96); **filial ~ centro custo** (0,91); **centro custo ~ faixa salarial** (0,88); **função ~ faixa salarial** (0,85); **centro custo ~ escala** (0,71); **tipo admissão ~ motivo admissão** (0,68); **jornada mensal ~ tipo vínculo** (0,62); **escala ~ função** (0,62). Estruturalmente: cada seção tem um único centro de custo (100%) e cada horário determina uma única escala (100%).

```
V(x,y) = sqrt( max(0, χ²/n - (k-1)(r-1)/(n-1)) / min(k*-1, r*-1) ) para todo par de colunas categóricas
```



Teste estatístico: qui-quadrado de independência para os 78 pares: 77 rejeitam H0 a 5%. Como n é grande, a significância é quase garantida; o que decide a redundância é o tamanho do efeito (V de Cramér no mapa).

Impacto: Num modelo, empresa + filial + centro de custo (ou função + salário) juntos geram coeficientes instáveis e efeitos não identificáveis; o efeito da escala se confunde com empresa e função (problema 4).

Tratamento proposto: Usar uma variável por grupo redundante (empresa; função agrupada; escala), regularização (ridge/lasso) quando houver muitas, e reportar o efeito da escala condicionado a empresa e função.

20. As colunas de minutos do ponto são ligadas por uma identidade contábil [BAIXO]

Afeta: T2

O que se esperava: Seis medidas distintas da jornada.

O que os dados mostram: A igualdade **trabalhado = previsto − falta − atraso + extra** vale exatamente em **84%** das linhas: as colunas são (quase) combinação linear umas das outras. Correlação trabalhado × previsto = 0,80.

```
(TRABALHADOS == PREVISTOS - FALTA - ATRASO + EXTRA).mean()
```

	previstos	falta	atraso	abono	trabalhados	extra
previstos	1.0	0.13	0.24	0.09	0.8	0.04
falta	0.13	1.0	-0.06	-0.02	-0.17	-0.03
atraso	0.24	-0.06	1.0	-0.06	-0.13	-0.09

	previstos	falta	atraso	abono	trabalhados	extra
abono	0.09	-0.02	-0.06	1.0	-0.04	-0.04
trabalhados	0.8	-0.17	-0.13	-0.04	1.0	0.42
extra	0.04	-0.03	-0.09	-0.04	0.42	1.0

Teste estatístico: fator de inflação da variância (VIF) de cada coluna regredida nas outras cinco: previstos = 44,1, falta = 5,6, atraso = 7,0, abono = 2,0, trabalhados = 50,8, extra = 6,9. previstos, trabalhados passam de 10 (multicolinearidade grave). Os VIFs só não são infinitos porque parte das linhas viola a identidade, o que é em si mais um sinal de inconsistência; nas linhas que a respeitam, a colinearidade é perfeita.

Impacto: Colocar as seis colunas num mesmo modelo gera multicolinearidade perfeita; as 16% de linhas que violam a identidade são outro sinal de inconsistência.

Tratamento proposto: Trabalhar com taxas derivadas (falta/previsto, abono/previsto) em vez das colunas brutas.

Parte 5 — O que confere

Para ser justo com a base, verificamos também o que está correto:

• Todas as contagens declaradas no PDF batem: 20.001 vínculos, 18.617 pessoas, 601.474 linhas de ponto, 5.052 afastamentos, 10.175 funções, 1.368 horários; admissões desde 21/07/1969 e última demissão em 13/10/2026.

• Chaves íntegras: toda função, horário e seção do cadastro existe na dimensão correspondente; nenhum ID duplicado; nenhuma linha duplicada no ponto (vínculo + data).

• Situação e demissão coerentes: todo vínculo com situação D tem data de demissão e todo demitido tem categoria (voluntário/involuntário).

• Os arquivos estão corretamente codificados em UTF-8.

• *dim_meta* (quadro atual e meta de motoristas) bate exatamente com os ativos do cadastro, exceto na empresa 5 (1.117 declarados contra 1.177 ativos). Ela pode servir de quadro-base do contrato:

empresa	ID_FUNCAO	FUNCAO	ATUAL	META	ativos no cadastro
5	5_2270	MOTORISTA DE ONIBUS	1117	1137	1.177
6	6_4201	MOTORISTA DE ONIBUS	24	25	24
6	6_4202	MOTORISTA DE ONIBUS	22	23	22
6	6_4204	MOTORISTA/CAMINHAO	557	572	557
6	6_4206	MOTORISTA/VEICULOS LEVES	14	16	14
8	8_1290	MOTORISTA DE ONIBUS	561	579	561
8	8_1291	MOTORISTA DE ONIBUS	21	22	21
8	8_1292	MOTORISTA DE ONIBUS	160	170	160

• Nota: o regulamento fala em "cerca de 4.500 colaboradores"; o cadastro tem 4.921 vínculos ativos (4.916 pessoas).

Resumo dos problemas e tratamentos

#	Problema	Severidade	Afeta	Tratamento
1	O ponto diário não cobre a maioria dos vínculos — e a empresa 5 não tem ponto nenhum	CRÍTICO	T2, T3	Calcular taxas de ausência onde há ponto e transferi-las para empresas sem ponto por função e tipo de jornada (estimativa por pares), sempre sinalizada como extrapolação e com intervalo de incerteza.
2	Na empresa 8, nenhum motorista em "REVEZAMENTO" tem ponto	CRÍTICO	T2, T3	Para os motoristas da empresa 8, usar apenas *fAfastamentos* (que os cobre) e completar faltas com taxas de pares.
3	A escala da maior parte dos motoristas de ônibus é desconhecida	CRÍTICO	T3	Tratar como cenários explícitos (ex.: "se REVEZAMENTO equivale a 6x1" / "se JORNADA MENSAL de 180h equivale a 5x2"), usando JORNADAMENSAL (minutos/mês) como pista, e reportar o resultado de cada cenário.
4	A escala 6x1 está concentrada numa única empresa e numa única função	ALTO	T3	Comparar dentro da mesma empresa e função (estratificação/regressão com controles) e explorar quem mudou de horário ao longo do ponto; declarar a limitação.
5	O ponto tem registros antes da admissão e depois da demissão	ALTO	T1, T2, T3	Filtrar o ponto por `DATAADMISSAO <= DATA <= DATADEMISSAO` antes de qualquer cálculo.
6	Há meses inteiros sem ponto dentro do contrato	MÉDIO	T2	Usar como denominador apenas os dias efetivamente registrados e marcar os meses sem ponto como faltantes (não como presença).
7	A escala do cadastro nem sempre é a escala praticada	ALTO	T3	Definir a escala de cada vínculo-mês pelo ponto (dias trabalhados observados) e usar o cadastro só como fallback.
8	Férias: o ponto e a tabela de afastamentos discordam	MÉDIO	T2	Usar a união das duas fontes (dia de férias se aparece em qualquer uma) e reportar a divergência.
9	O evento DESLIGAMENTO em afastamentos não confere com o cadastro	MÉDIO	T1	Usar exclusivamente *dim_integrante* (DATADEMISSAO + CATEGORIA_DESLIGAMENTO) para a Trilha 1.
10	fAfastamentos: duplicados, sobreposições e eventos fora do período	MÉDIO	T2	Deduplicar, unir intervalos sobrepostos por vínculo e recortar no período; eventos sem fim tratados como em curso até 30/09/2026.
11	Minutos impossíveis e ausências "invisíveis" no ponto	MÉDIO	T2	Truncar minutos ao intervalo [0, 1440]; tratar o dia previsto e não trabalhado sem justificativa como ausência não registrada (análise de sensibilidade com e sem).
12	Ponto de vínculos que não existem no cadastro	BAIXO	T2	Descartar (impacto desprezível).
13	A mesma pessoa com vínculos sobrepostos ou recontratada em dias	MÉDIO	T1	Calcular o turnover em duas versões: oficial (por vínculo) e por pessoa, desconsiderando transferências e recontratações em até 3 dias.
14	Salário é nominal e da época da última alteração	MÉDIO	Custo	Usar salário só dos ativos (custo do contrato) ou relativizar ao piso da função no mesmo ano.
15	FAIXA_ETARIA não é a idade atual (nem documentada)	BAIXO	T1	Usar apenas para vínculos do período (onde a idade na saída é próxima da atual) e declarar a premissa.
16	Colunas prometidas ausentes ou sem informação	MÉDIO	T1, T3	Criar um agrupamento próprio de funções (motorista de ônibus, cobrador, motorista de caminhão, aprendiz, outros) e ignorar TURNO/TIPO_JORNADA.
17	Feriados do ponto não batem com dim_feriados	BAIXO	T2, T3	Usar o FERIADO do próprio ponto (reflete o calendário local) e dim_feriados só para projeção.
18	Datas incoerentes no cadastro	BAIXO	T1	Excluir o caso negativo; manter os de 0 dias (são admissões e rescisões reais para o turnover).
19	Variáveis categóricas do cadastro são fortemente redundantes	MÉDIO	T1, T3	Usar uma variável por grupo redundante (empresa; função agrupada; escala), regularização (ridge/lasso) quando houver muitas, e reportar o efeito da escala condicionado a empresa e função.
20	As colunas de minutos do ponto são ligadas por uma identidade contábil	BAIXO	T2	Trabalhar com taxas derivadas (falta/previsto, abono/previsto) em vez das colunas brutas.

Conclusão. Nenhum problema impede o trabalho, mas três deles (1, 2 e 3) restringem o que pode ser medido diretamente: a rotatividade (Trilha 1) é calculável para todas as empresas a partir do cadastro; ausências (Trilha 2) só são observadas diretamente nas empresas 6, 3 e 7; e a escala praticada (Trilha 3) é desconhecida para os motoristas de ônibus das empresas 5 e 8. Nossas estimativas para esses grupos serão apresentadas como cenários, com as premissas explícitas.